

Análisis de Bases de Datos Transaccionales Tienda-Online

Paola Andrea Gómez Orozco

Nilson Adolfo Páez Suárez

Universidad de La Sabana

Maestría en Inteligencia Artificial, Inmersión a la Programación

Dr. Cs. en Física .Miguel Ángel Laverde

Junio de 2026

Introducción

Las base de datos entregada en esta actividad tiene como objetivo poder implementar la metodología de algoritmos de clustering y reducción de dimensionalidad para analizar el comportamiento de los clientes de una tienda ubicada en el Reino Unido, la información corresponde al período comprendido entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011, cada registro tienen datos como el país de origen, código de factura, número de cliente, producto ofertado, precio, cantidad y fecha de compra, con los anteriores registros de la base de datos de los más 541.909 filas y 8 columnas, se analiza los registros muestran las diferentes solicitudes de compras, cancelaciones, ingreso de transacciones fallidas, de clientes atípicos, o frecuentes, con el desarrollo de esta unidad 4 se busca comprender a profundidad técnicas de clustering como K-means e Isolation Forest estas, utilizadas para segmentar clientes y la última se utilizará con el fin de encontrar anomalías con algoritmos no supervisados.

Fases del Análisis de Datos, preparación de datos

Como paso inicial se realizó la identificación y renombramiento de las variables que conforman la base de datos(número de factura, código de producto, descripción, cantidad, fecha de factura, precio unitario, código de cliente y país), se identifican los siguientes datos relevantes, se identifican 38 países de origen de las solicitudes de compras, asociadas a 4372 usuarios.

Cantidad de países: 38
Cantidad de productos: 4070
Cantidad de usuarios: 4372

Figura 1. Identificación de Variable de la Base de datos

En la exploración de las bases de datos se identifica que el mayor número de ventas se reporta del reino Unido, aunque no es relevante si va mostrando la tendencia del potencial de los clientes que realizan compras, y se muestra, aunque las compras que solicitan del exterior son interesantes, la relevancia de ser una tienda de origen del Reino Unido (UK) se muestra en el siguiente gráfico.




Figura 2. Relación de mayor número de ventas según el país

La cantidad de solicitudes en el Reino Unido es alrededor de 19857, se resalta que los países que más solicitan y compran productos son países vecinos en Europa, esto representan una porción pequeña de la tienda.

Se verifico que valores faltantes existen en la base datos en la columna de Nombre producto se realiza un mapeo de la base de datos completando 1,342 de los 1,454 y dejando solo 112 datos nulos del nombre del producto completando los campos en la columna nombre del producto con los id de Cliente o Código de Cliente

Numero_factura	0	Numero_factu	0
Cod_prod	0	Cod_prod	0
Nombre_Producto	1454	Nombre_Proc	112
Cantidad	0	Cantidad	0
Fecha_compra	0	Fecha_compra	0
Precio unitario	0	Precio unitari	0
Cod_Cliente	135080	Cod_Cliente	135080
País	0	País	0
dtype: int64			

Figura 3. Mapeo de Bases de datos Nombre de Producto

Otras de la practicas para implementar las técnicas de clustering, fue dejar dos bases de datos una balanceando el número de registros, eliminando la información de la columna clientes que aparecen sin número ID o celda vacía, se eliminaron 135.080 filas, debido a que estos datos influyen en la segmentación, se recurre a este arreglo de suprimir dichos registros de la base de datos, para fallas de anomalías por la técnica de Isolation Forest se alimenta un base alterna sin la eliminación de los registros vacíos de la columna de identificación de cliente, se evidencian códigos que no pertenecen a transacciones reales como POST, DOT, M,BANK CHARGES, AMAZONFEE, CRUK, PADS, C2 y B), como característica primordial se identifica que la columna de factura que tiene el número acompañado de la letra C, resaltándolos como transacciones fallidas, montos que se cancelan con las transacciones inicialmente debitadas.

Análisis de Variables Pre-Estandarización

La cantidad de registros depurados muestran que los 4372 clientes tienen relación directa con variables como el porcentaje de facturas canceladas (Tasa de cancelación), días transcurridos desde la última compra (Recency), numero asociadas al cliente, (Frequency), gasto neto total, incorporando el efecto de las devoluciones (Monetary), variable para distinguir compradores frecuentes de bajo valor de compradores esporádicos de alto valor por transacción Ticket promedio (Monetary/Frequency).

Para poder realizar la agrupación de clientes se calculó su relación y se determinó grupos relevantes donde cada fila es un registro de cliente en la figura 4 se muestra la correlación entre si de las variables, se encuentra una correlación alta y ratificada entre variables como (Monetary/Frequency), tasa de cancelación, cantidad de variables, que son determinantes para el análisis de K-mens,




Figura 4. Mapeo de Bases de datos Nombre de Producto

Para cada uno de los 4,372 clientes identificados se calcularon las siguientes variables:

- **Recency:** días transcurridos desde la última compra hasta la fecha de corte (10/12/2011)
- **Frequency:** número de facturas únicas asociadas al cliente.
- **Monetary:** gasto neto total, incorporando el efecto de las devoluciones.
- **Ticket promedio:** $\text{Monetary} / \text{Frequency}$, útil para distinguir compradores frecuentes de bajo valor de compradores esporádicos de alto valor por transacción.
- **Diversidad de productos:** número de productos distintos comprados.
- **Tasa de cancelación:** proporción de facturas canceladas sobre el total de facturas del cliente

Se analizó la distribución de las variables y se identificaron datos incompletos en la columna Cod_Cliente, adicionalmente por contener una asimetría alta presentan alto sesgo en su distribución espectral, por lo que se aplicó transformación logarítmica, con signo especialmente de los registros de cancelación de productos, al realizar este ajuste permitió excluir que valores altos dando una limpieza de base, con el objetivo que la clusterización o segmentación no quedara movida hacia un número de pequeño de valores extremos.




Figura 5. Distribución de Recency, Frequency, Monetary, Ticket promedio, Diversidad de productos y Tasa de cancelación

Aplicación de técnicas de Segmentación (Clustering) no Supervisadas

Teniendo lista la base de datos, se verificó la eliminación de 5225 filas duplicadas, adicionalmente cambiando y corrigiendo el tipo de variable de texto a fecha, número a categoría, excluyendo los códigos de productos especiales que no hacían referencia a transacciones reales o por cancelaciones de productos, estas acciones contribuyeron a no contaminar la base de datos, se procedió a buscar segmentos de comportamiento normal, al generar graficas de las variables RFM, se evidencia que las seis variables presentan un sesgo muy marcado por posibles anomalías, esto hace necesario generar una gráfica logarítmica, con estas acciones se garantiza que cualquier logaritmo basado en distancias pueda segmentar el comportamiento del cliente típico sin sufrir ambigüedades.




Figura 6. Relación entre pares de variables Recency, Frequency, Monetary,

La Figura 6 muestra la fuerte tendencia a la dispersión de datos cuando no se utiliza la grafica tipo logarítmica, centralizando la gráfica a los datos mínimos, convergiendo hacia al extremo inferior, demostrando que el ajuste de la escala es necesaria para aplicar en las bases de datos y generar un análisis mediante el modelo Isolation Forest sobre el espacio RFM transformado, de manera satisfactoria y encontrar anomalías.

K-means sobre variables RFM (Modelo Principal)

Para entrena el modelo K-means se efectuó sobre 5 variables que fueron previamente trasformados y estandarizadas los datos de estudio fueron de los 4319 clientes o códigos. Para determinar el número de clúster se empleó 3 métodos, el del codo, el método de índice Calinski-Harabasz y el coeficiente de silueta (Figura 7)




Figura 7 Método del codo, índice Calinski-Harabasz y coeficiente de silueta para k entre 2 y 10, calculados sobre los clientes sin atípicos. La línea roja marca k=4, el valor elegido

El coeficiente de silueta se mantuvo bajo y relativamente plano en todo el rango evaluado (entre 0.23 y 0.37), lo cual indica que el comportamiento de los clientes es más un espectro continuo que bloques discretos bien separados, al comparar cada uno de estos de concluyo que el número de clústeres como constante k para entrenar al modelo es de K=4, a partir de esta zona de 4-6 en los dos primeros métodos la inercia comienza a estabilizarse, esta segmentación es relevante para determinar el comportamiento de la tienda. El coeficiente de silueta obtenido en k=4 fue de 0.257.

Los resultados de la segmentación se presentan en el siguiente gráfico, el modelo fue entrenado con las 5 variables indicadas anteriormente, como dato relevante todas variables fueron estandarizadas.

	No. Clientes	Recency	Frequency	Monetary	Ticket_promedio	Tasa_cancelacion
Cluster						
0	1438	108.1	2.2	969.6	480.7	0.0
1	1404	135.4	1.9	260.6	143.4	0.0
2	1314	19.8	11.6	4638.6	351.2	0.0
3	163	116.3	4.9	880.9	167.7	0.2

Para interpretar mejor cada grupo se revisó la distribución de cada variable dentro de cada clúster (gráficos de cajas) y la ubicación de los clústeres en el espacio Frequency vs. Monetary y Recency vs. Monetary.




Figura 8. Distribución de Recency, Frequency, Monetary y Ticket_promedio por clúster sin escala logarítmica.

La figura 8 muestra las gráficas achatadas hacia el extremo inferior ya que hay datos que son extremos, y para incluir y no afectar la base de datos, se realiza una gráfica logarítmica como se muestra en la figura 8




Figura 9. Distribución de Recency, Frequency, Monetary y Ticket_promedio por clúster con escala logarítmica.

Descripción de cada segmento de clientes

Clúster 0 – Clientes ocasionales (1438 Clientes): compran pocas veces (2,2 facturas en promedio) y su última compra fue hace 108,1 días en promedio, pero su ticket promedio (£480,7) es el más alto de los cuatro grupos y su gasto total (£969,6) es el segundo más alto. Es el segmento más numeroso.

Clúster 1 – Clientes de bajo valor (1.404 clientes): compran con una frecuencia similar a la del clúster 0 (1,9 facturas en promedio), pero gastan menos en total (£260,6) y son los que llevan más tiempo sin comprar (135,4 días en promedio). Su ticket promedio (£143,4) es también el más bajo de los cuatro grupos. Es el segmento de menor valor para la tienda.

Clúster 2 – Clientes frecuentes y de alto valor (1314 clientes): son los clientes mas activos y recientes, (11,6 facturas en promedio) y una ultima compra hace solo 19,8 días. Su gasto total (£4.638,6) es, por mucho, el más alto de los cuatro grupos, aunque su ticket promedio (£351,2) es moderado porque compran en muchas facturas pequeñas. Son los clientes más valiosos para la tienda.

Clúster 3 – Clientes con cancelaciones frecuentes (163 clientes): compran con una frecuencia media (4,9 facturas) y su última compra fue hace 116,3 días en promedio, similar al clúster 0. Su ticket promedio (£167,7) y su gasto total (£880,9) son moderados, similares a los de los clústeres 0 y 1. Lo que realmente distingue a este grupo es su tasa de cancelación (20%), muy por encima del 0% de los demás clústeres, lo que indica un comportamiento de compra-devolución particular más que un nivel de gasto distinto.

Técnica DBSCAN (verificación por densidad)

Como segunda técnica, se aplicó DBSCAN (eps=0.9, min_samples=7) sobre el mismo espacio de variables, el clúster generado se aplicó a 4166 clientes agrupados en un solo segmento dominante, 10 clúster secundario y 143 marcaron ruido. El resultado muestra el comportamiento de los clientes no presenta densidades naturalmente separadas, la información que es ambigua o es considerada ruido pueden ser agrupados junto con 53 datos

atípicos con Isolation Forest. En la figura 7 se muestra la distribución en plano 3D de la distribución por la Técnica DBSCAN




Figura 10. Resultado de la técnica DBSCAN

Técnica K-means sobre componentes principales (verificación dimensional)

Las 5 variables RFM que fueron analizadas en la matriz de correlación, fueron reducidas a tres componentes fundamentales, en el modelo K-means se aplicó una constante $K=3$, al reducir el número de clústeres, se identifica que esta segmentación no da el resultado de una variable de negocio interpretable, el aplicar este modelo se utiliza como evidencia de una tratamiento genuina de los datos, pero no se toma como principal modelo debido a que no muestran resultados que arrojen una comprensión más global del negocio.




Figura 11. Resultado de la técnica DBSCAN dispersión en el espacio 2D

Detección de transacciones atípicas o anómalas

Para identificar las transacciones anómalas se empleó el algoritmo Isolation Forest, este algoritmo no exige que tenga información anómala o normal, adicionalmente se incluye pa análisis con la base de datos, la información completa sin eliminar los datos en blanco que se encuentran en la columna de código Clientes, como hay una diferenciación de dichos datos, se puede realizar una segmentación, se estableció una contaminación esperada del 1% el resultado se visualiza el siguiente gráfico, se marcaron 5,308 transacciones como anómalas




Figura 12. Transacciones normales y anómalas según cantidad y monto (escala logarítmica simétrica).

Las transacciones marcadas como anómalas presentan, en promedio, una cantidad 33 veces mayor (250.5 frente a 7.5 unidades) y un monto 31 veces mayor (£441.3 frente a £14.1) que las transacciones normales, se ve como dato relevante que los códigos de cliente 12346 y 16446, junto con los clientes con código 14646 y 17450, son las anomalías de mayor valor o magnitud, también se evidencia que la tienda no tiene transacciones el sábado

Cientes atípicos identificados

En total se identificaron 81 clientes para revisión separada de la segmentación principal: 53 por comportamiento extremo en el espacio RFM (Isolation Forest) y 28 por tratarse de cuentas cuyo único registro es una devolución sin compra asociada.

Validación visual con t-SNE




Figura 13. Misma proyección t-SNE de los clientes, coloreada por las etiquetas de K-means (izquierda) y de DBSCAN(derecha).

La proyección t-SNE que realiza relación de vecindad o cercanía y no solo varianza, a diferencia de PCA, muestra los 4 cuatros sectores o clústeres de k-means, ocupan regiones predominantes distintas, el modelo por DBSCAN centraliza la mayor parte de los datos prácticamente en una sola región, por consiguiente, se identifica que este modelo no logra capturar la estructura K-means inicialmente realizada.

Conclusiones

El proceso de depuración y transformación de la base de datos fue determinante para lograr obtener resultados confiables en el modelo de aprendizaje no supervisado. Se eliminaron registros duplicados, se trataron valores faltantes y se identificaron transacciones canceladas lo que permitió construir una base de datos sólida para la segmentación de clientes.

La incorporación de variables RFM (Recency, Frequency y Monetary), complementadas con indicadores como el ticket promedio, la diversidad de productos y la tasa de cancelación, permitió caracterizar de manera más completa el comportamiento de los clientes, mejorando la capacidad de los algoritmos para identificar patrones de compra.

Debido a que las variables presentaban valores muy dispersos y algunos datos extremadamente altos, fue necesario aplicar una transformación logarítmica y estandarizar la información. Esto permitió reducir la influencia de esos valores extremos y obtener una segmentación de clientes más representativa de su comportamiento real.

El algoritmo K-Means fue el modelo que proporcionó la segmentación más útil para el análisis del negocio. La selección de cuatro clústeres ($k = 4$), respaldada por los métodos del codo, el índice de Calinski-Harabasz y el coeficiente de silueta, permitió identificar grupos de clientes con características diferenciadas en términos de frecuencia de compra, nivel de gasto y antigüedad de la última compra.

La aplicación de Isolation Forest permitió separar previamente los clientes con comportamiento atípico, evitando que estos influyeran negativamente en el entrenamiento del modelo K-Means. Esta estrategia mejoró la estabilidad de la segmentación y facilitó el análisis del comportamiento de los clientes habituales.

La técnica DBSCAN permitió verificar que la mayoría de los clientes presentan un comportamiento similar y pertenecen a un mismo grupo, mientras que solo una pequeña cantidad de clientes mostraron comportamientos diferentes o poco frecuentes. Esto indica que los clientes no se encuentran divididos en grupos completamente separados, sino que sus comportamientos son muy parecidos entre sí, lo cual también explica por qué el coeficiente de silueta obtuvo un valor moderado.

El análisis realizado permitió identificar comportamientos importantes en las ventas de la tienda. Se evidenció que la mayor cantidad de compras se realiza en el Reino Unido, que existen horarios y días en los que se concentran más ventas y que algunos productos tienen una demanda mucho mayor que otros. Esta información puede servir para apoyar la toma de decisiones relacionadas con las ventas, el inventario y la planificación de las actividades.

En general, los resultados obtenidos demuestran que las técnicas de aprendizaje no supervisado son una herramienta útil para conocer mejor el comportamiento de los clientes y apoyar la toma de decisiones. La segmentación obtenida permite identificar clientes con características similares, reconocer aquellos que generan un mayor valor para la tienda,

detectar comportamientos poco comunes y apoyar el diseño de estrategias comerciales más enfocadas en las necesidades de los clientes.

En respuesta a las preguntas planteadas en la actividad, se concluye que sí fue posible segmentar a los clientes de acuerdo con su comportamiento de compra utilizando técnicas de clustering; igualmente, fue posible identificar transacciones anómalas y clientes atípicos mediante el algoritmo Isolation Forest. Estos resultados demuestran que las técnicas de aprendizaje no supervisado permiten descubrir patrones ocultos en grandes volúmenes de información y constituyen una herramienta valiosa para apoyar la toma de decisiones basada en datos dentro de una organización.