

Análisis de Base de Datos Transaccionales: Segmentación de Clientes y Detección de Anomalías mediante Aprendizaje No Supervisado

Unidad 4 — Aprendizaje No Supervisado
Maestría en Inteligencia Artificial
Universidad de La Sabana

Nilson

1. Preparación y Exploración de Datos Transaccionales

1.1 Descripción general del conjunto de datos

El conjunto de datos analizado corresponde a las transacciones de una tienda minorista en línea, sin establecimiento físico, con sede en el Reino Unido y especializada en artículos de regalo. Cubre el periodo comprendido entre el 01/12/2010 y el 09/12/2011, con 541,909 registros transaccionales y 8 variables: número de factura, código de producto, descripción, cantidad, fecha de factura, precio unitario, código de cliente y país.

1.2 Tratamiento de datos faltantes

El 24.9% de los registros (135,080 filas) no tiene código de cliente asociado, lo que representa el 14.9% de los ingresos totales registrados. El análisis de este subconjunto descarta que se trate de un patrón aleatorio: su distribución geográfica es prácticamente idéntica al resto de la base (98.8% Reino Unido), no corresponde mayoritariamente a cancelaciones, y los productos involucrados son artículos reales del catálogo, no solo cargos administrativos. Esto sugiere que se trata de compras realizadas sin un registro de cliente asociado (por ejemplo, como invitado), más que de un error de captura.

Se decidió excluir estas filas del análisis a nivel de cliente (segmentación RFM), pero conservarlas en una versión paralela del conjunto de datos para el análisis de anomalías a nivel de transacción, donde identificar al cliente no es un requisito.

1.3 Limpieza de datos

Se eliminaron 5,225 filas exactamente duplicadas dentro del subconjunto de clientes identificados (de 406,829 a 401,604 filas). Se excluyeron del análisis de comportamiento de compra los códigos que no corresponden a productos reales (cargos de envío, ajustes contables y comisiones: POST, DOT, M, BANK CHARGES, AMAZONFEE, CRUK, PADS, C2 y B). Las cancelaciones, identificables por el prefijo "C" en el número de factura, no se excluyeron: al sumar el gasto por cliente, una devolución resta exactamente lo que la compra original sumó, por lo que el efecto se neutraliza de forma natural sin necesidad de un tratamiento adicional.

Se identificaron además 28 clientes cuyo único registro en todo el periodo es una devolución, sin ninguna compra asociada bajo su mismo identificador. La explicación más probable es que su compra original corresponda a una de las transacciones sin cliente identificado descritas en el numeral 1.2, y que solo en el momento de la devolución el sistema capturara su identificador. Estos 28 clientes se excluyeron de la segmentación principal, ya que no representan un patrón de compra real, y se reportan por separado como hallazgo de calidad de datos en la sección de negocio.

1.4 Ingeniería de características (RFM extendido)

Para cada uno de los 4,372 clientes identificados se calcularon las siguientes variables:

- **Recency:** días transcurridos desde la última compra hasta la fecha de corte (10/12/2011).
- **Frequency:** número de facturas únicas asociadas al cliente.
- **Monetary:** gasto neto total, incorporando el efecto de las devoluciones.

- **Ticket promedio:** Monetary / Frequency, útil para distinguir compradores frecuentes de bajo valor de compradores esporádicos de alto valor por transacción.
- **Diversidad de productos:** número de productos distintos comprados.
- **Tasa de cancelación:** proporción de facturas canceladas sobre el total de facturas del cliente.

Estas variables presentaron un sesgo extremo (coeficientes de asimetría entre 5.6 y 21.7, siendo Monetary la más afectada), por lo que se aplicó una transformación logarítmica —logarítmica con signo para las variables con valores negativos— antes de estandarizar y modelar. Esta transformación fue necesaria para que el algoritmo de clusterización no quedara dominado por un pequeño número de valores extremos.

2. Selección y Aplicación de Técnicas No Supervisadas

2.1 Separación de clientes atípicos (primera etapa)

Antes de buscar segmentos de comportamiento "normal", se aplicó Isolation Forest sobre el espacio RFM transformado para aislar clientes con comportamiento extremo —por ejemplo, compras mayoristas puntuales de decenas de miles de unidades seguidas de una cancelación total—. Se identificaron 53 clientes atípicos (1.2% de la base), que se excluyeron del modelo de segmentación principal y se reportan por separado en la sección de negocio.

2.2 K-means sobre variables RFM (modelo principal)

Se entrenó K-means sobre las cinco variables RFM transformadas y estandarizadas de los 4,319 clientes "normales" restantes. El número de clústeres se determinó combinando el método del codo, el índice Calinski-Harabasz y el coeficiente de silueta (Figura 1).




Figura 1. Método del codo, índice Calinski-Harabasz y coeficiente de silueta para k entre 2 y 10, calculados sobre los clientes sin atípicos. La línea roja marca k=4, el valor elegido.

El coeficiente de silueta se mantuvo bajo y relativamente plano en todo el rango evaluado (entre 0.23 y 0.37), lo cual indica que el comportamiento de los clientes es más un espectro continuo que bloques discretos bien separados, un resultado consistente con lo reportado en la literatura para este tipo de variables de comportamiento de consumo. Se eligió k=4 por ubicarse en la zona donde la reducción de inercia comienza a estabilizarse, priorizando además que el número de segmentos resultara útil para una narrativa de negocio. El coeficiente de silueta obtenido en k=4 fue de 0.257.

2.3 DBSCAN (verificación por densidad)

Como segunda técnica, se aplicó DBSCAN (eps=0.9, min_samples=7) sobre el mismo espacio de variables. El resultado fue casi degenerado: 4,166 clientes agrupados en un único clúster dominante, 10 en un clúster secundario y 143 marcados como ruido. Este resultado refuerza la conclusión del numeral 2.2: el espacio de comportamiento de los clientes no presenta densidades naturalmente separadas. Los 143 puntos de ruido se consideran candidatos adicionales a revisar junto con los 53 atípicos detectados con Isolation Forest.

2.4 K-means sobre componentes principales (verificación dimensional)

Como tercera técnica, las cinco variables RFM se redujeron a tres componentes principales (91.1% de la varianza explicada) y se aplicó K-means con $k=3$ sobre ese espacio reducido. Este modelo obtuvo un coeficiente de silueta más alto (0.376), pero sus ejes —combinaciones lineales de las variables originales— no se traducen directamente en una variable de negocio interpretable. Se utiliza como evidencia de que existe estructura genuina en los datos, pero no se adopta como modelo principal por su menor interpretabilidad de negocio.

2.5 Detección de anomalías a nivel de transacción

De forma independiente al análisis por cliente, se aplicó Isolation Forest sobre 531,376 líneas de transacción individuales —excluyendo códigos administrativos y precios no positivos—, usando como variables la cantidad, el precio unitario, el monto, la hora de compra y el día de la semana. Con una tasa de contaminación del 1%, se marcaron 5,308 transacciones como anómalas.

3. Interpretación y Evaluación de Resultados

3.1 Perfil de los segmentos de clientes

La Tabla 1 resume las características promedio de cada uno de los cuatro segmentos resultantes del modelo principal (K-means, k=4):

Clúster	Nombre del segmento	n	Recencia (días)	Frecuencia (órdenes)	Gasto total (£)	Ticket prom. (£)	Tasa cancel.
2	VIP activos	1,314	19.8	11.6	4,638.6	351.2	0.0%
0	Ocasionales de ticket alto	1,438	108.1	2.2	969.6	480.7	0.0%
1	Bajo valor / en riesgo	1,404	135.4	1.9	260.6	143.4	0.0%
3	Alta tasa de cancelación	163	116.3	4.9	880.9	167.7	20.0%

Tabla 1. Perfil promedio de los cuatro segmentos de clientes (4,319 clientes, atípicos excluidos).




Figura 2. Comparación visual del gasto total, número de órdenes y recencia promedio por segmento.




Figura 3. Distribución (no solo el promedio) de frecuencia y gasto total por segmento.

3.2 Comparación de los tres modelos de clustering

Modelo	Resultado	Silueta	Interpretabilidad	Rol en el análisis
K-means sobre RFM (k=4)	4 grupos balanceados (163 – 1,438 clientes)	0.257	Alta	Modelo principal
DBSCAN (eps=0.9)	1 grupo dominante (4,166) + 1 pequeño (10) + ruido (143)	N/A*	Baja	Verificación de densidad
K-means sobre PCA (k=3)	3 grupos sobre componentes principales	0.376	Media	Verificación dimensional

Tabla 2. Comparación de los tres modelos aplicados. *DBSCAN no se optimiza mediante el coeficiente de silueta de la misma forma que K-means, dado que no todos los puntos pertenecen a un clúster.

3.3 Validación visual con t-SNE




Figura 4. Misma proyección t-SNE de los clientes, coloreada por las etiquetas de K-means (izquierda) y de DBSCAN (derecha).

La proyección t-SNE —que preserva relaciones de vecindad y no solo varianza lineal, a diferencia de PCA— muestra que las cuatro etiquetas de K-means ocupan regiones predominantemente distintas del espacio, lo que confirma de forma independiente que existe una estructura genuina detrás de la segmentación. En contraste, la misma proyección coloreada con las etiquetas de DBSCAN exhibe un único color dominante que cubre casi toda la superficie, incluyendo zonas que K-means separó con claridad. Esta es evidencia visual adicional de que DBSCAN, con los parámetros evaluados, no logra capturar la estructura que K-means sí encuentra.

Es importante precisar que esta proyección constituye una validación cualitativa, no una métrica cuantitativa: las distancias entre grupos en un gráfico de t-SNE no son directamente interpretables, y el resultado depende del parámetro de perplejidad utilizado (30 en este caso).

3.4 Transacciones anómalas




Figura 5. Transacciones normales y anómalas según cantidad y monto (escala logarítmica simétrica).

Las transacciones marcadas como anómalas presentan, en promedio, una cantidad 33 veces mayor (250.5 frente a 7.5 unidades) y un monto 31 veces mayor (£441.3 frente a £14.1) que las transacciones normales. Entre las anomalías de mayor magnitud se encuentran los clientes 12346 y 16446 —los mismos identificados como atípicos en el análisis RFM—, junto con los clientes 14646 y 17450, que también figuran entre los de mayor gasto histórico acumulado de toda la base. Esta coincidencia entre dos métodos independientes —agregación por cliente y detección a nivel de transacción individual— refuerza la validez de estos hallazgos.

3.5 Clientes atípicos identificados

En total se identificaron 81 clientes para revisión separada de la segmentación principal: 53 por comportamiento extremo en el espacio RFM (Isolation Forest, sección 2.1) y 28 por tratarse de cuentas cuyo único registro es una devolución sin compra asociada (sección 1.3).

4. Análisis de Negocio y Conclusiones

4.1 ¿Se pueden segmentar los clientes según la cantidad de transacciones y el valor que gastan?

Sí. Se identificaron cuatro segmentos con perfiles claramente diferenciables:

- **VIP activos** (1,314 clientes, 30.4% de la base): compra reciente (20 días), alta frecuencia (12 órdenes) y el mayor gasto total acumulado (£4,639). Es el segmento prioritario para estrategias de retención, dado su peso desproporcionado en los ingresos de la tienda.
- **Ocasionales de ticket alto** (1,438, 33.3%): baja frecuencia (2 órdenes) pero el ticket promedio más alto de los cuatro segmentos (£481). Es compatible con el perfil de clientes mayoristas esporádicos que menciona la guía de la actividad.
- **Bajo valor / en riesgo de abandono** (1,404, 32.5%): la inactividad más alta (135 días sin comprar), baja frecuencia y el menor gasto total (£261). Candidatos naturales para campañas de reactivación.
- **Alta tasa de cancelación** (163, 3.8%): tasa de devolución del 20%, frente a 0% en el resto de segmentos. Es el segmento más pequeño, pero el único con un comportamiento de devolución sistemático que amerita revisión de procesos.

4.2 ¿Se pueden identificar transacciones anómalas en este registro?

Sí. El 1% del volumen transaccional (5,308 líneas, sobre 531,376 evaluadas) se aparta sustancialmente del comportamiento normal, con cantidades y montos entre 30 y 33 veces superiores al promedio. La mayoría corresponde a pedidos de gran volumen compatibles con compras mayoristas puntuales; un número menor podría corresponder a errores de captura que conviene validar manualmente antes de tratarlos como ventas legítimas en futuros reportes financieros.

4.3 ¿Se pueden identificar clientes atípicos?

Sí. 81 clientes (1.9% de la base) muestran un comportamiento que se aparta de los cuatro segmentos principales: 53 por compras o cancelaciones de magnitud extrema, y 28 por tener únicamente un registro de devolución sin compra asociada, hallazgo ligado al mismo problema de captura de datos identificado en la sección 1.2. Varios de estos clientes (12346, 16446, 14646, 17450) fueron confirmados de forma cruzada tanto en el análisis por cliente como en la detección de anomalías a nivel de transacción, lo cual refuerza la confianza en estos hallazgos.

4.4 Recomendaciones

- Diseñar una campaña de retención dirigida al segmento VIP activo, que representa el 30% de la base pero el mayor peso individual en ingresos.
- Implementar una campaña de reactivación para el segmento de bajo valor, inactivo en promedio hace más de cuatro meses y que representa una tercera parte de la base de clientes.
- Revisar manualmente los procesos asociados al segmento de alta tasa de cancelación (163 clientes) para identificar causas raíz: calidad del producto, exactitud de la descripción en el catálogo,

o errores logísticos en el despacho.

- Investigar puntualmente las transacciones y los clientes atípicos señalados en este informe, antes de descartarlos automáticamente como ruido en análisis futuros.
- A nivel de gobierno de datos, corregir el mecanismo que deja sin identificador de cliente a una cuarta parte de las transacciones, ya que limita la trazabilidad de devoluciones y el potencial de personalización comercial.

Nota metodológica: este informe resume los resultados del análisis; el desarrollo técnico completo (limpieza de datos, ingeniería de características, entrenamiento y evaluación de los modelos) se encuentra documentado en el notebook de Python adjunto a esta actividad.